

Cosca

Enterprise AI Orchestration Platform

Um sistema de **orquestração de agentes** com um cérebro de conhecimento curado — não um chatbot.

Plataforma de produção: delega executivos por hierarquia, busca por entendimento, e protege a integridade com assinatura criptográfica.

A plataforma em números

61

Agentes especializados

88

Skills operacionais

39

Workflows

123

Comandos CLI

19.3k

Entradas de conhecimento

15.7k

Vetores semânticos

Engenharia

234 packages Go · 1.024 arquivos-fonte · 843 testes

Modelo próprio: **Cosca-Qwen3-4B-LoRA** (*cosca-qwen3-4b-lora-001*) — 2× mais rápido que o modelo anterior, com raciocínio estruturado.

O que o torna diferente

1. Não é um chatbot — é uma organização

O Cosca implementa uma **hierarquia operacional**: **Don** → **Kernel** → **CEO** → **CTO** → **Chiefs** → **Specialists**. O Kernel **roteia e nunca implementa** — delega a agentes com papel definido, como uma empresa real. Cada agente tem domínio, capacidades e responsabilidades.

2. Busca por entendimento, não por palavra

Usa **busca híbrida**: FTS5 (BM25) + similaridade vetorial (cosseno, embeddings locais 768-dim) + grafo de conhecimento. Entende o **significado** — uma query "proteção da casa" retorna conteúdo sobre segurança/família, mesmo sem as palavras iguais.

3. Conhecimento com proveniência

Todo conhecimento é classificado (FATO / EVIDÊNCIA / INFERÊNCIA) e rastreável. **"Zero achismo"** — sem evidência, é hipótese, marcada como tal. A busca não inventa o que não existe.

4. Memória que evolui e se cura

O kernel **aprende com cada sessão** (auto-evolução). A memória é curada — aprendizado obsoleto vira superseded, erros são registrados em `failures.md`.

Memória > Velocidade.

5. Integridade criptográfica

Uma **family chain** assinada (Ed25519 + DPAPI machine-bound) protege a identidade. Se o histórico é alterado, o sistema **bloqueia o boot** (fail-closed).
Sandbox + JWT autenticação em camadas.

Capacidades-chave

Domínio	O que o Cosca faz
Orquestração	61 agentes em hierarquia, delegação por capacidade, workflows com gate de aprovação
Conhecimento	19.3k entradas curadas, busca híbrida semântica, proveniência, memória auto-evolutiva
Visão	Motor ONNX nativo (CLIP, SAM, Deep) + OCR — percepção local offline
Voz / Áudio	STT/TTS (sherpa), mic nativo, pipeline de áudio
Mundo 3D	Ponte Unreal (WebSocket real) + Blender end-to-end + procgen determinístico
Ciência	Engine reproduzível (observed/calculated/simulated/generated) + integridade
Realtime	Durable execution, stallwatch, compute fabric, tasks duráveis

Treino

Pipeline LoRA próprio (destilação teacher→student → GGUF → Ollama)

Segurança & Governança

- **Family chain** Ed25519 + DPAPI — machine-bound, testemunho de imutabilidade
- **Fail-closed** em cada camada — na dúvida, tranca
- **JWT** com anti-enumeração + rotação de tokens
- **Sandbox** (bwrap Linux/WSL2) + loopback-only REST
- **Sistema de níveis** de soberania (L1/L2/L3) com watchdog auto-descida
- **Constituição** — 8 princípios imutáveis + garantias do Don

Arquitetura de dados (ADR-013)

Não usa banco monolítico. Dados particionados em **módulos físicos < 100 MB** (Core/Grafo/Projects/Vetores), cada um coeso. O índice vetorial é regenerável — nunca fonte.

Certificação GOLD

O sistema foi validado de ponta a ponta: **go vet limpo, 7.431 testes PASS, QGate 9736/9736**, chain íntegra, conhecimento consistente. Estado conhecido-bom documentado e recuperável.

Documento de capacidade gerado a partir do estado verificado do sistema (2026-09-05).
Números medidos em execução real.