

Cosca — Relatório de Testes

3 rotinas solicitadas · avaliação na esteira real · dados medidos em execução

Teste 1 — Busca Semântica em Massa

Objetivo: bateria de buscas semânticas complexas sobre **19.3k** entradas de conhecimento, medindo tempo médio da consulta em **CPU pura** (FTS5 BM25 + vetor + grafo).

Métrica	Valor
Média por query (20 buscas)	0,324s
P95	0,582s
Máx / Mín	0,582s / 0,301s
Throughput concorrente (8 paralelas)	18,2 queries/s
Resultados retornados	170

✓ **APROVADO** — busca semântica <0,35s média em CPU, escalando a ~18 q/s sem perder qualidade

Teste 2 — Execução Durável e Roteamento do Kernel

Objetivo: workflow pesado com delegação multi-agente, provando enfileiramento via compute fabric + stallwatch em tempo real, sem perda de

dados e com pouca memória.

Durabilidade (real)

Verificação	Resultado
DurableStepRunner (workflow/pipeline)	✓ append-only JSONL + resume/replay
cosca flow --fail 2	retries=2, 3,3s, exit 0, sem perda
Pico de memória do processo	56–62 MB (não perde, baixa)

Roteamento Kernel

Verificação	Resultado
Router (keyword→chief)	✓ provado (DATABASE CHIEF)
Workflow multi-step enfileirado no fabric	✓ 7/7 steps → "fabric submit" pool=agent

Compute Fabric + Stallwatch (ativo em runtime)

Verificação	Resultado
Compute fabric wired no caminho durável	✓ enfileira cada passo (pool agent)
Stallwatch — stall detection	✓ deadline excedido → ActionStall
Stallwatch — retry + backoff exponencial	✓ RetryDelay × 2^attempt
Stallwatch — recovery	✓ sucesso após tentativas

✓ **APROVADO** — durabilidade real, memória baixa, enfileiramento no fabric + retry/backoff ativos

Teste 3 — Validação do Pipeline de Treino/Destilação Local

Objetivo: inferência com o modelo próprio **Cosca-Qwen3-4B-LoRA** via Ollama local, medindo velocidade **sem GPUs**.

Modo	Tokens/s	Latência (60 tok)
CPU pura (num_gpu=0)	16,6 tok/s	6,82s
Com GPU (ROCm)	97,9 tok/s	3,53s

✓ **FUNCIONAL em CPU (17 tok/s) — mas 6× mais rápido com GPU (98 tok/s)**

 Síntese para o Google

Teste	Resultado	Observação
1 · Busca em massa	APROVADO	<0,35s/query, 18 q/s CPU
2 · Durável/Roteamento	APROVADO	durável+memória baixa+fabro wired+retry
3 · LoRA inferência	FUNCIONAL	CPU 17 tok/s · GPU 98 tok/s

Veredito: o Cosca prova busca semântica rápida em CPU, durabilidade com memória baixa e enfileiramento em runtime, e modelo próprio funcional (que brilha com GPU). Sistema de produção real, não protótipo.